گزارش فاز اول پروژه آماری

بررسی رابطه شاخص توده بدنی و فشار خون سیستولیک در بزرگسالان بر اساس داده‌های NHANES (۲۰۲۱–۲۰۲۳)

درس: آمار و کاربرد آن

نام و نام خانوادگی: محمدمحسن عباس‌زاده

شماره دانشجویی: ۴۰۱۱۰۰۴۳۳

استاد درس: دکتر علیشاهی

آبان ۱۴۰۵

۱. مقدمه و معرفی پژوهش

شاخص توده بدنی (Body Mass Index یا BMI) یکی از شاخص‌های متداول برای ارزیابی وضعیت بدنی افراد است. فشار خون سیستولیک نیز یکی از شاخص‌های مهم در بررسی وضعیت سلامت قلب و عروق به شمار می‌رود.

هدف این پروژه بررسی رابطه آماری بین شاخص توده بدنی و فشار خون سیستولیک در بزرگسالان ۲۰ سال به بالا است. علاوه بر این، سن و جنس به‌عنوان متغیرهای تکمیلی در بررسی و توصیف الگوهای داده‌ها مورد توجه قرار می‌گیرند.

داده‌های این پژوهش از طرح ملی سلامت و تغذیه ایالات متحده آمریکا (NHANES) مربوط به دوره آگوست ۲۰۲۱ تا آگوست ۲۰۲۳ استخراج شده‌اند.

این مطالعه از نوع مشاهده‌ای و مقطعی است. بنابراین، هدف آن بررسی ارتباط آماری بین متغیرهاست و نتایج آن به‌تنهایی نشان‌دهنده رابطه علت و معلولی نیستند.

۲. معرفی منبع داده و ساختار مجموعه‌داده

۱.۲. منبع داده

NHANES یک پیمایش ملی است که توسط مرکز ملی آمار سلامت ایالات متحده (NCHS) اجرا می‌شود. این پیمایش با استفاده از مصاحبه‌ها، معاینات فیزیکی و آزمایش‌های مختلف، اطلاعاتی درباره وضعیت سلامت و تغذیه جمعیت ایالات متحده گردآوری می‌کند.

داده‌های مورد استفاده در این پروژه مربوط به دوره August ۲۰۲۱–August ۲۰۲۳ هستند.

منابع رسمی:

- وب‌سایت NHANES:

https://www.cdc.gov/nchs/nhanes/

- معرفی دوره ۲۰۲۱–۲۰۲۳:

https://wwwn.cdc.gov/nchs/nhanes/continuousnhanes/overviewbrief.aspx?Cycle=2021-2023

۲.۲. فایل‌های مورد استفاده

برای انجام این پژوهش از سه فایل اصلی استفاده شده است:

نام فایل	محتوای اصلی
DEMO_L	اطلاعات جمعیت‌شناختی، سن، جنس و متغیرهای مربوط به وزن و طراحی پیمایش
BMX_L	اندازه‌گیری‌های بدن، از جمله شاخص توده بدنی
BPXO_L	اندازه‌گیری‌های فشار خون

این فایل‌ها با استفاده از شناسه مشترک شرکت‌کنندگان، یعنی `SEQN`، به یکدیگر متصل شده‌اند.

هر ردیف از مجموعه‌داده نهایی نمایانگر یک شرکت‌کننده است. از آنجا که در فایل فشار خون ممکن است برای هر فرد چند اندازه‌گیری ثبت شده باشد، پیش از ادغام، اندازه‌گیری‌های معتبر فشار خون سیستولیک برای هر فرد خلاصه شده‌اند.

۳.۲. واحد مشاهده و ساختار داده‌ها

واحد مشاهده در این پژوهش، هر شرکت‌کننده در پیمایش NHANES است.

متغیرهای اصلی مورد استفاده عبارت‌اند از:

- سن شرکت‌کننده
- جنس ثبت‌شده در مجموعه‌داده
- شاخص توده بدنی (BMI)
- فشار خون سیستولیک
- وزن نمونه‌گیری و متغیرهای طراحی پیمایش

فشار خون سیستولیک هر فرد، در صورت وجود چند اندازه‌گیری معتبر، با محاسبه میانگین اندازه‌گیری‌های معتبر موجود خلاصه شده است. همچنین تعداد اندازه‌گیری‌های معتبر هر فرد ثبت شده است.

۳. روش نمونه‌گیری و قابلیت تعمیم نتایج

NHANES از روش نمونه‌گیری احتمالی چندمرحله‌ای و پیچیده استفاده می‌کند. در این روش، افراد و گروه‌های مختلف جمعیت با احتمال‌های متفاوت انتخاب می‌شوند تا نمونه بتواند نماینده جمعیت هدف باشد.

جمعیت هدف این پیمایش، جمعیت غیرنظامیِ غیرساکن در مؤسسات سازمانی ایالات متحده است.

به دلیل پیچیده بودن روش نمونه‌گیری، برای برآوردهای قابل تعمیم به جمعیت هدف نمی‌توان همواره از محاسبات ساده و بدون وزن استفاده کرد. وزن‌های نمونه‌گیری و متغیرهای طراحی پیمایش باید متناسب با نوع متغیرها و روش تحلیل در نظر گرفته شوند.

در این پروژه، وزن معاینه `WTMEC2YR` و متغیرهای طراحی `SDMVSTRA` و `SDMVPSU` بررسی و برای مراحل تحلیلی نگهداری شده‌اند.

۴. بررسی اولیه و کیفیت داده‌ها

۱.۴. تعداد مشاهدات در فایل‌های اولیه

در ابتدا، ابعاد سه مجموعه‌داده بررسی شد.

فایل	تعداد ردیف	تعداد ستون
DEMO_L	۱۱۹۳۳	۲۷
BMX_L	۸۸۶۰	۲۲
BPXO_L	۷۸۰۱	۱۲

شناسه `SEQN` در هر سه فایل بررسی شد. این شناسه در هر فایل دارای مقدار معتبر و یکتا بود و رکورد تکراری بر اساس آن مشاهده نشد.

۲.۴. بررسی داده‌های گمشده و مقادیر غیرعادی

پیش از تحلیل، متغیرهای اصلی از نظر مقادیر گمشده، دامنه مقادیر و موارد غیرعادی بررسی شدند.

در فایل‌های NHANES، برخی متغیرها ممکن است دارای کدهای ویژه یا مقادیر گمشده باشند. بنابراین، صرفاً بررسی مقادیر خالی نرم‌افزاری برای تشخیص تمام موارد کافی نیست و باید ساختار داده و مستندات رسمی نیز مورد توجه قرار گیرد.

در بررسی متغیر سن (RIDAGEYR)، تعداد ۱۸۹ مقدار غیرعادی با مقدار بسیار کوچک و یکسان مشاهده شد. این مقادیر به‌عنوان موارد نیازمند بررسی شناسایی شدند و در مرحله پاک‌سازی به‌صورت مقدار گمشده در نظر گرفته شدند. این تصمیم با هدف جلوگیری از تفسیر اشتباه مقادیر غیرعادی به‌عنوان سن واقعی اتخاذ شد.

در متغیر وزن معاینه (WTMEC2YR) نیز مقادیر بسیار کوچک و غیرواقعی در بخشی از رکوردها مشاهده شد که با افراد دارای وضعیت مصاحبه بدون معاینه مطابقت داشتند. این موارد به‌عنوان مقادیر معتبر وزن تفسیر نشدند.

۳.۴. بررسی اندازه‌گیری‌های فشار خون

در فایل BPXO_L برای هر شرکت‌کننده حداکثر سه اندازه‌گیری فشار خون سیستولیک وجود داشت.

تعداد اندازه‌گیری‌های معتبر برای هر فرد به شرح زیر بود:

تعداد اندازه‌گیری معتبر	تعداد افراد
صفر	۲۸۳
یک	۱۲
دو	۲۸
سه	۷۴۷۸
مجموع	۷۸۰۱

برای هر فرد، میانگین اندازه‌گیری‌های معتبر موجود محاسبه شد. افرادی که هیچ اندازه‌گیری معتبر سیستولیک نداشتند، مقدار معتبری برای متغیر میانگین فشار خون دریافت نکردند.

این روش باعث شد اطلاعات افراد دارای یک یا دو اندازه‌گیری معتبر نیز حفظ شود؛ با این حال، تعداد اندازه‌گیری‌های هر فرد در تفسیر نتایج باید مورد توجه قرار گیرد.

۵. ادغام فایل‌ها و انتخاب نمونه تحلیلی

۱.۵. ادغام مجموعه‌داده‌ها

سه فایل با استفاده از شناسه `SEQN` به یکدیگر متصل شدند. فایل جمعیت‌شناختی به‌عنوان فایل پایه در نظر گرفته شد و اطلاعات BMI و فشار خون به آن اضافه شد.

پس از ادغام، مجموعه‌داده شامل ۱۱۹۳۳ ردیف و ۳۰ ستون بود. تعداد شناسه‌های یکتا نیز ۱۱۹۳۳ بود.

۲.۵. انتخاب جمعیت مورد بررسی

برای پاسخ به سؤال پژوهش، تحلیل به افراد ۲۰ سال و بالاتر محدود شد.

فرایند انتخاب نمونه به صورت مرحله‌ای انجام شد:

مرحله	تعداد افراد باقی‌مانده
کل افراد در فایل جمعیت‌شناختی	۱۱۹۳۳
افراد دارای سن معتبر و حداقل ۲۰ سال	۷۸۰۹
افراد بزرگسال دارای BMI معتبر	۵۹۷۰
افراد دارای BMI و فشار خون سیستولیک معتبر	۵۸۰۵

بنابراین، نمونه نهایی تحلیل اصلی شامل **۵۸۰۵ شرکت‌کننده** است.

در این فرایند، ۱۸۳۹ نفر از افراد بزرگسال به دلیل نداشتن BMI معتبر از تحلیل اصلی کنار گذاشته شدند. سپس ۱۶۵ نفر دیگر به دلیل نداشتن فشار خون سیستولیک معتبر در نمونه نهایی قرار نگرفتند.

حذف مشاهدات دارای داده‌های گمشده می‌تواند بر ویژگی‌های نمونه نهایی اثر بگذارد؛ بنابراین، نتایج باید با توجه به این محدودیت تفسیر شوند.

۶. متغیرهای پژوهش و مقیاس اندازه‌گیری

متغیرهای مورد استفاده در این پژوهش در جدول زیر معرفی شده‌اند:

متغیر	نام در داده‌ها	نوع متغیر	مقیاس
شاخص توده بدنی	BMXBMI	کمی پیوسته	نسبتی
فشار خون سیستولیک	متغیر محاسبه‌شده از BPXOSY1 تا BPXOSY3	کمی پیوسته	نسبتی
سن	RIDAGEYR	کمی ثبت‌شده بر حسب سال کامل	نسبتی
جنس ثبت‌شده	RIAGENDR	کیفی اسمی	اسمی
وزن معاینه	WTMEC2YR	کمی	نسبتی
طبقه نمونه‌گیری	SDMVSTRA	کیفی کدگذاری‌شده	اسمی
خوشه نمونه‌گیری	SDMVPSU	کیفی کدگذاری‌شده	اسمی

در سؤال اصلی، BMI متغیر توضیحی و فشار خون سیستولیک متغیر پاسخ در نظر گرفته شده است. سن و جنس نیز برای بررسی و توصیف الگوهای احتمالی تفاوت بین گروه‌ها مورد استفاده قرار می‌گیرند.

۷. آمار توصیفی متغیرهای اصلی

در این بخش، شاخص‌های مرکزی و پراکندگی متغیرهای BMI و فشار خون سیستولیک در نمونه نهایی محاسبه شده‌اند.

۱.۷. آمار توصیفی شاخص توده بدنی

شاخص آماری	مقدار
تعداد مشاهدات	۵۸۰۵
میانگین	۲۹/۷۳
انحراف معیار	۷/۱۵
حداقل	۱۱/۱
چارک اول	۲۴/۷
میانه	۲۸/۴
چارک سوم	۳۳/۵
حداکثر	۶۸/۹
دامنه بین چارکی (IQR)	۸/۸

میانگین BMI در نمونه نهایی حدود ۲۹/۷۳ و میانه آن ۲۸/۴ است. بالاتر بودن میانگین نسبت به میانه می‌تواند نشان‌دهنده وجود مقداری چولگی به سمت راست در توزیع BMI باشد.

دامنه بین چارکی برابر ۸/۸ است؛ یعنی نیمی از مشاهدات BMI در فاصله بین ۲۴/۷ و ۳۳/۵ قرار دارند.

۲.۷. آمار توصیفی فشار خون سیستولیک

شاخص آماری	مقدار
تعداد مشاهدات	۵۸۰۵
میانگین	۱۲۲/۸۷
انحراف معیار	۱۷/۹۹
حداقل	۷۰
چارک اول	۱۱۰/۶۷
میانه	۱۲۰/۳۳
چارک سوم	۱۳۲/۶۷
حداکثر	۲۱۵
دامنه بین چارکی (IQR)	۲۲

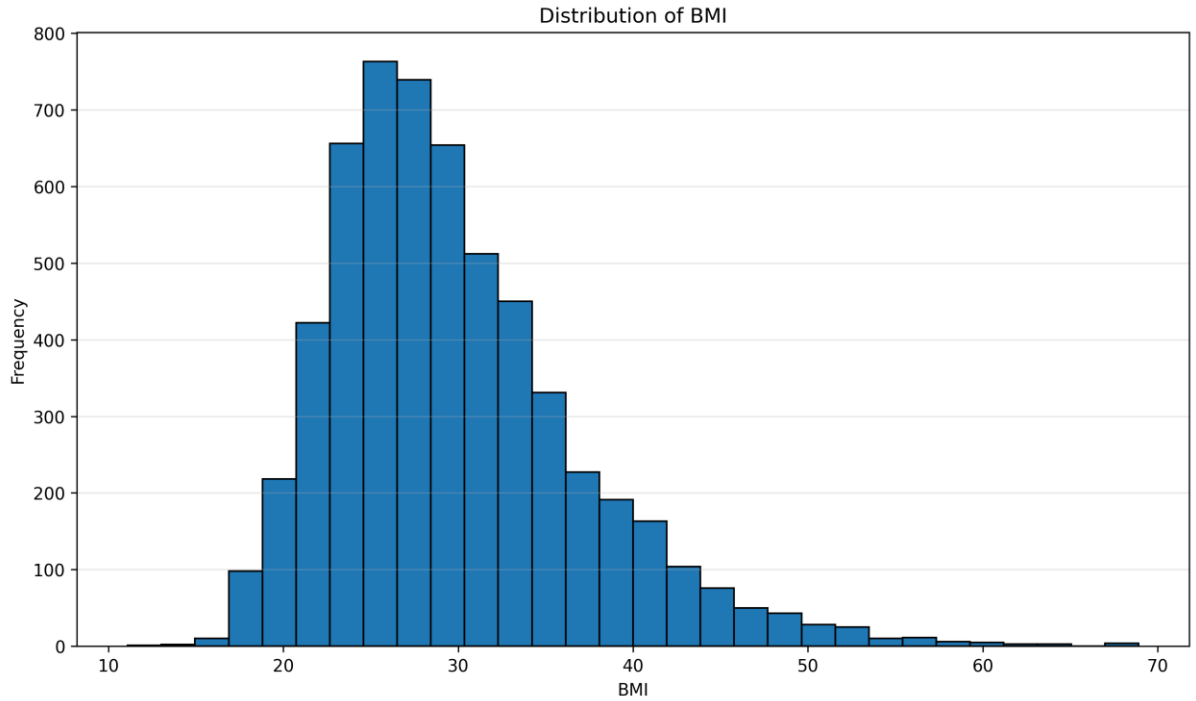
میانگین فشار خون سیستولیک در نمونه نهایی حدود ۱۲۲/۸۷ میلی‌متر جیوه و میانه آن حدود ۱۲۰/۳۳ میلی‌متر جیوه است.

انحراف معیار حدود ۱۷/۹۹ و دامنه بین چارکی ۲۲ میلی‌متر جیوه است که نشان‌دهنده پراکندگی قابل توجه مقادیر فشار خون در میان شرکت‌کنندگان است.

۸. بررسی نموداری متغیرها

برای شناخت بهتر شکل توزیع متغیرها و بررسی رابطه احتمالی میان آن‌ها، چهار نمودار تهیه شده است.

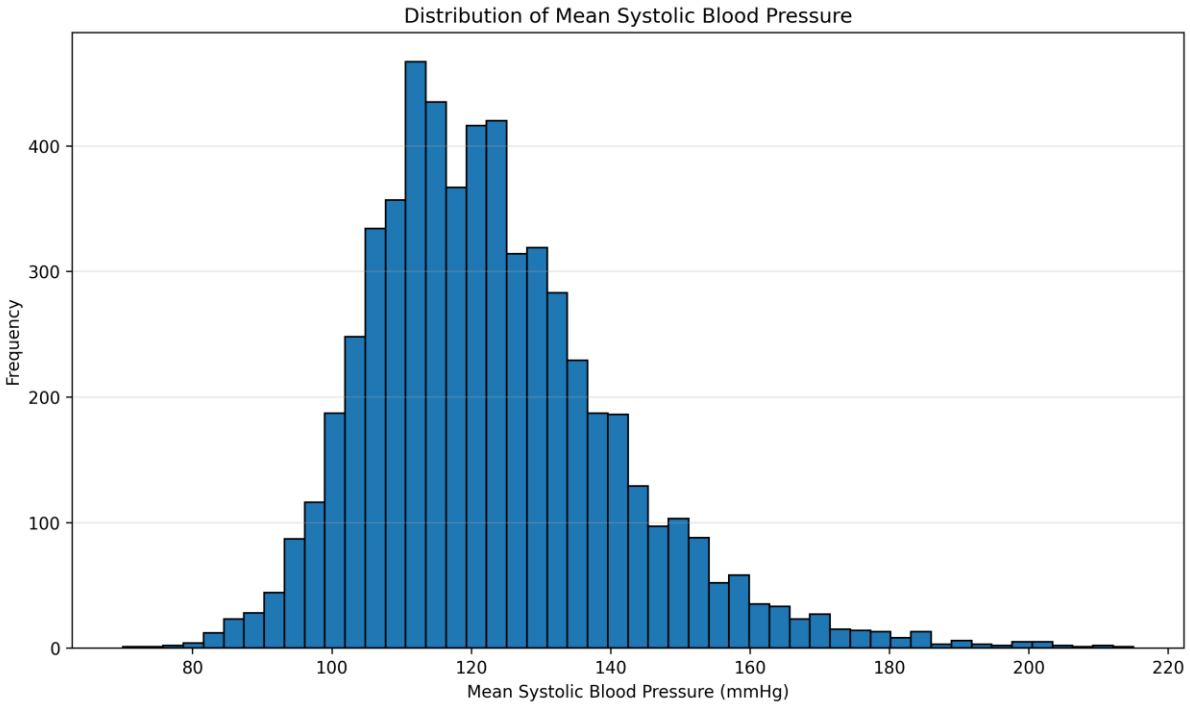
۱.۸. توزیع شاخص توده بدنی



شکل ۱ ـ توزیع شاخص توده بدنی در نمونه تحلیلی

نمودار هیستوگرام BMI نشان می‌دهد که بیشتر مقادیر در محدوده میانی توزیع قرار دارند و در سمت مقادیر بزرگ‌تر، دنباله‌ای به سمت راست مشاهده می‌شود. این الگو با بالاتر بودن میانگین نسبت به میانه نیز سازگار است.

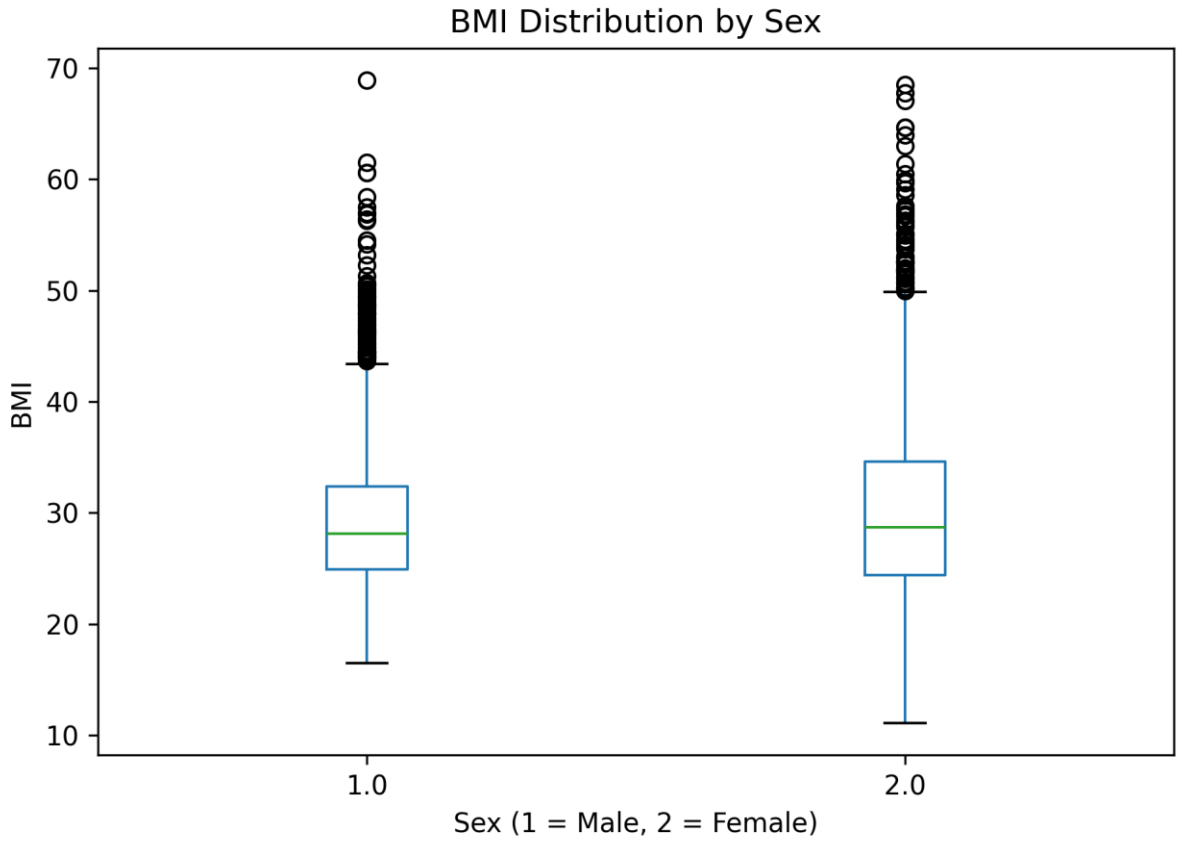
۲.۸. توزیع فشار خون سیستولیک



شکل ۲ ـ توزیع میانگین فشار خون سیستولیک در نمونه تحلیلی

نمودار فشار خون سیستولیک نشان‌دهنده پراکندگی مقادیر در دامنه نسبتاً گسترده‌ای است. بیشتر مشاهدات در محدوده میانی توزیع قرار دارند و تعدادی مقدار بزرگ‌تر نیز در دنباله سمت راست دیده می‌شوند.

۳.۸. مقایسه توزیع BMI بر اساس جنسیت



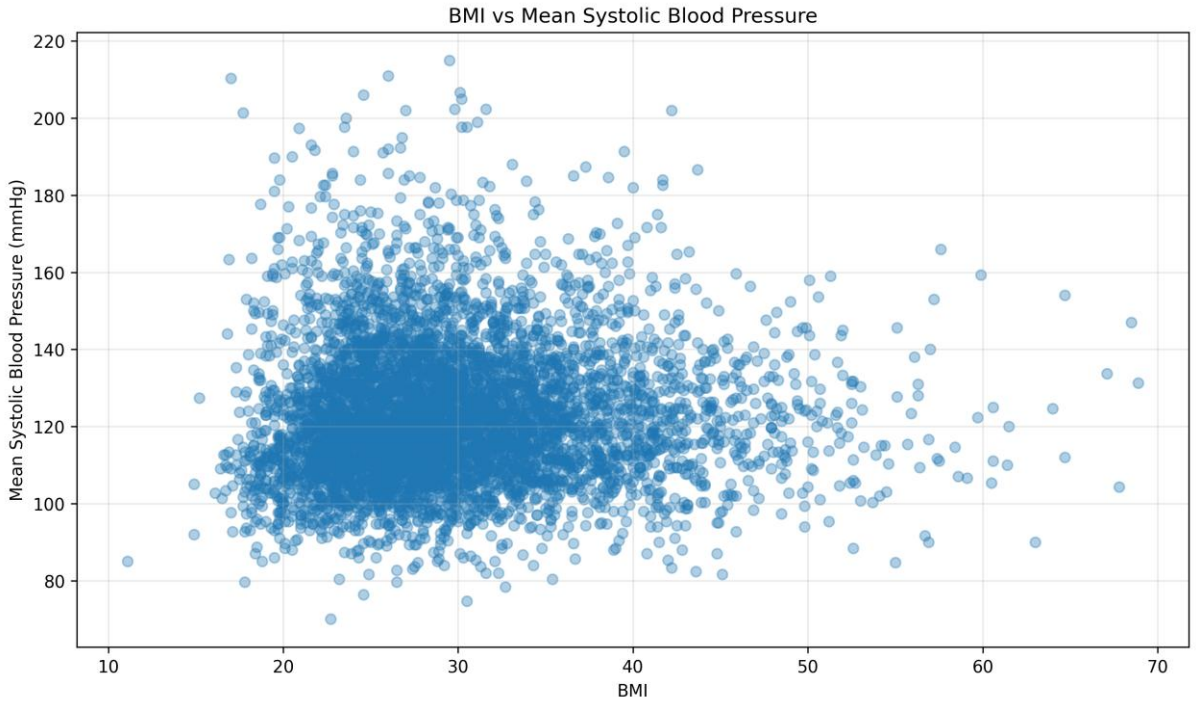
شکل ۳ ـ مقایسه توزیع شاخص توده بدنی در دو گروه جنسیتی

نمودار جعبه‌ای برای مقایسه میانه، پراکندگی و مقادیر دورافتاده BMI در دو گروه جنسیتی استفاده شده است.

بر اساس نمودار، میانه BMI در گروه زنان اندکی بالاتر از گروه مردان به نظر می‌رسد و میزان پراکندگی نیز در دو گروه یکسان نیست. در هر دو گروه، مقادیر دورافتاده مشاهده می‌شود.

این مقایسه توصیفی است و به‌تنهایی برای نتیجه‌گیری درباره وجود تفاوت آماری معنادار کافی نیست.

۴.۸. بررسی رابطه BMI و فشار خون سیستولیک



شکل ۴ ـ نمودار پراکنش شاخص توده بدنی و میانگین فشار خون سیستولیک

نمودار پراکنش برای بررسی الگوی ارتباط بین BMI و فشار خون سیستولیک رسم شده است.

بخش عمده مشاهدات در محدوده BMI حدود ۲۰ تا ۴۰ و فشار خون سیستولیک حدود ۹۰ تا ۱۵۰ قرار دارند. با مشاهده نمودار، الگوی خطی مشخص و قدرتمندی میان دو متغیر دیده نمی‌شود.

برای بررسی عددی رابطه خطی، ضریب همبستگی پیرسون نیز محاسبه شده است.

۹. بررسی وزن‌های نمونه‌گیری

۱.۹. وزن و متغیرهای طراحی پیمایش

از آنجا که داده‌های NHANES حاصل نمونه‌گیری پیچیده هستند، وزن‌های نمونه‌گیری برای در نظر گرفتن تفاوت احتمال انتخاب افراد و تعدیل عدم پاسخ و سایر عوامل طراحی پیمایش اهمیت دارند.

در این پروژه، متغیرهای زیر بررسی شده‌اند:

- `WTMEC2YR`: وزن نمونه‌گیری مربوط به معاینات
- `SDMVSTRA`: شناسه طبقه نمونه‌گیری

- `SDMVPSU`: شناسه خوشه نمونه‌گیری

در نمونه نهایی ۵۸۰۵ نفری، مقادیر وزن نمونه‌گیری معتبر و مثبت بودند. همچنین، ۱۵ طبقه نمونه‌گیری و ۳۰ ترکیب طبقه و خوشه در داده‌ها مشاهده شد.

۲.۹. مقایسه میانگین خام و وزن‌دار

برای بررسی اثر استفاده از وزن‌های نمونه‌گیری بر برآورد میانگین‌ها، میانگین خام و میانگین وزن‌دار دو متغیر اصلی محاسبه و مقایسه شدند.

متغیر	میانگین خام	میانگین وزن‌دار
BMI	۲۹/۷۳۰	۲۹/۶۰۰
فشار خون سیستولیک	۱۲۲/۸۶۹	۱۲۱/۱۱۷

در هر دو متغیر، میانگین وزن‌دار کمتر از میانگین خام است. این تفاوت نشان می‌دهد که در نظر گرفتن وزن‌های نمونه‌گیری می‌تواند بر مقدار برآورد میانگین اثر بگذارد.

با این حال، محاسبه میانگین وزن‌دار به‌تنهایی به معنی انجام کامل تحلیل پیمایشی نیست. برای محاسبه خطای استاندارد، فاصله اطمینان و آزمون‌های استنباطی باید ساختار پیچیده نمونه‌گیری، شامل طبقات و خوشه‌ها، نیز در روش آماری لحاظ شود.

۱۰. بررسی رابطه خطی بین BMI و فشار خون سیستولیک

برای بررسی رابطه خطی بین دو متغیر اصلی، ضریب همبستگی پیرسون محاسبه شد.

مقدار به‌دست‌آمده برابر است با: $r = ۰/۰۲۷۴$

این مقدار نشان‌دهنده رابطه خطی خام بسیار ضعیف و مثبت بین BMI و فشار خون سیستولیک در نمونه تحلیلی است.

با توجه به نزدیک بودن ضریب همبستگی به صفر، در این بررسی اولیه رابطه خطی قابل توجهی بین دو متغیر مشاهده نمی‌شود.

با این حال، این نتیجه به‌تنهایی نبود هرگونه رابطه را اثبات نمی‌کند؛ زیرا ممکن است رابطه غیرخطی باشد یا متغیرهایی مانند سن در الگوی مشاهده‌شده نقش داشته باشند.

همچنین، این ضریب همبستگی خام و بدون تعدیل برای سن، جنس یا طراحی نمونه‌گیری محاسبه شده است؛ بنابراین نباید آن را به‌عنوان نتیجه نهایی درباره جمعیت هدف تفسیر کرد.

۱۱. جمع‌بندی و نتیجه‌گیری فاز اول

در فاز اول این پروژه، داده‌های NHANES مربوط به دوره آگوست ۲۰۲۱ تا آگوست ۲۰۲۳ شناسایی و بررسی شدند. سه مجموعه‌داده جمعیت‌شناختی، اندازه‌گیری‌های بدن و فشار خون با استفاده از شناسه مشترک شرکت‌کنندگان ادغام شدند.

پس از بررسی کیفیت داده‌ها، شناسایی مقادیر گمشده و غیرعادی و محدود کردن جمعیت مورد مطالعه به بزرگسالان ۲۰ سال به بالا، نمونه نهایی شامل ۵۸۰۵ شرکت‌کننده دارای BMI و فشار خون سیستولیک معتبر تشکیل شد.

آمار توصیفی نشان داد که میانگین BMI در نمونه نهایی حدود ۲۹/۷۳ و میانگین فشار خون سیستولیک حدود ۱۲۲/۸۷ میلی‌متر جیوه است.

نمودارهای اکتشافی برای بررسی توزیع متغیرها، مقایسه BMI بین گروه‌های جنسیتی و مشاهده رابطه احتمالی BMI و فشار خون سیستولیک تهیه شدند.

ضریب همبستگی پیرسون برابر با حدود ۰/۰۲۷۴ به دست آمد که نشان‌دهنده رابطه خطی خام بسیار ضعیف و مثبت بین دو متغیر در نمونه بررسی‌شده است. این نتیجه مقدماتی است و برای بررسی دقیق‌تر رابطه، لازم است در مراحل بعدی نقش متغیرهای تکمیلی و ساختار نمونه‌گیری مورد توجه قرار گیرد.

در مجموع، بررسی‌های انجام‌شده نشان دادند که داده‌های NHANES از نظر وجود متغیرهای مورد نیاز و امکان اتصال فایل‌ها، برای مطالعه پرسش آماری اصلی مناسب هستند. با این حال، وجود داده‌های گمشده، طراحی پیچیده پیمایش و مقطعی بودن داده‌ها از محدودیت‌هایی هستند که باید در تحلیل و تفسیر نتایج مورد توجه قرار گیرند.

۱۲. محدودیت‌های پژوهش

مهم‌ترین محدودیت‌های شناسایی‌شده در این مرحله عبارت‌اند از:

۱. **داده‌های گمشده:** بخشی از شرکت‌کنندگان اطلاعات معتبر BMI یا فشار خون سیستولیک نداشتند و در نتیجه در نمونه نهایی تحلیل اصلی قرار نگرفتند. اگر افراد حذف‌شده از نظر ویژگی‌های مهم با افراد باقی‌مانده متفاوت باشند، نتایج ممکن است تحت تأثیر قرار بگیرند.

۲. **نمونه‌گیری پیچیده:** برای برآوردهای قابل تعمیم به جمعیت هدف، وزن‌ها، طبقات و خوشه‌های نمونه‌گیری باید به‌درستی در روش تحلیل لحاظ شوند.

۳. **خطای اندازه‌گیری:** اندازه‌گیری‌های BMI و فشار خون ممکن است با خطا همراه باشند. همچنین تعداد اندازه‌گیری‌های معتبر فشار خون برای افراد یکسان نیست.

۴. **ماهیت مقطعی داده‌ها:** اطلاعات این دوره وضعیت افراد را در یک دوره بررسی نشان می‌دهد و برای اثبات رابطه علت و معلولی یا بررسی تغییرات افراد در طول زمان کافی نیست.

۵. **متغیرهای تکمیلی:** عواملی مانند سن، جنس و سایر ویژگی‌های سلامت ممکن است در ارتباط مشاهده‌شده نقش داشته باشند. بررسی کامل این عوامل به تحلیل‌های تکمیلی نیاز دارد.

۱۳. منابع

۱. National Health and Nutrition Examination Survey (NHANES), August ۲۰۲۱–August ۲۰۲۳. National Center for Health Statistics (NCHS).

۲. NHANES ۲۰۲۱–۲۰۲۳ Overview:

https://wwwn.cdc.gov/nchs/nhanes/continuousnhanes/overviewbrief.aspx?Cycle=2021-2023

۳. NHANES official website:

https://www.cdc.gov/nchs/nhanes/

۴. فایل‌های داده مورد استفاده:

- DEMO_L:

  https://wwwn.cdc.gov/Nchs/Data/Nhanes/Public/2021/DataFiles/DEMO_L.xpt
- BMX_L:

  https://wwwn.cdc.gov/Nchs/Data/Nhanes/Public/2021/DataFiles/BMX_L.xpt
- BPXO_L:

  https://wwwn.cdc.gov/Nchs/Data/Nhanes/Public/2021/DataFiles/BPXO_L.xpt